OrchAI

Mimari Doküman

LLM Orchestration Backend — v1.0 | Mart 2026

---

1. Proje Amacı

OrchAI; bir Python backend'i içinde LLM'in nerede ve nasıl kullanılacağını somutlaştıran bir PoC (Proof of Concept) sistemidir. Sistem; gelen kullanıcı isteklerini analiz ederek üç farklı akışa yönlendirir, MongoDB'de kalıcı hafıza yönetimi sağlar ve her istekte token/maliyet logu tutar.

---

2. Sistem Mimarisi — Akış Diyagramı

2.1 Genel Akış

Aşağıdaki diyagram, bir kullanıcı isteğinin sistemde nasıl işlendiğini göstermektedir:

Katman	Bileşen	Sorumluluk
1 — API	FastAPI Route (/api/v1/chat)	HTTP isteği al, validate et, orchestrator'a ilet
2 — Orchestrator	LLMOrchestrator	Routing karar ver, akışı koordine et, response döndür
3a — Direct	LLMService (OpenAI)	Basit sorular için doğrudan GPT-4o-mini çağrısı
3b — RAG	RetrievalService + LLMService	MongoDB doküman ara, context oluştur, GPT-4o-mini
3c — Web	WebService + LLMService	DuckDuckGo ara, context oluştur, Claude Sonnet
4 — Memory	MemoryService	Short/long term memory oku/yaz
5 — Trace	TraceService	Token/cost/latency log kaydet
6 — Response	Pydantic ChatResponse	Yapılandırılmış yanıt döndür

2.2 Detaylı Akış

Adım 1 — İstek Alımı:

- POST /api/v1/chat endpoint'ine mesaj + opsiyonel session_id + opsiyonel force_route gelir
- FastAPI ChatRequest modeli ile validate edilir

Adım 2 — Session Yönetimi:

- session_id yoksa yeni UUID üretilir
- sessions koleksiyonunda kayıt oluşturulur/kontrol edilir

Adım 3 — Memory Context:

- memory_store'dan uzun vadeli özet alınır (varsa)
- messages koleksiyonundan son N mesaj alınır (short_term)
- İkisi birleştirilerek system prompt oluşturulur

Adım 4 — Routing Kararı:

- force_route varsa direkt kullanılır
- WEB keyword kontrolü yapılır (bugün, güncel, haber...)
- RAG keyword kontrolü yapılır (nedir, nasıl, chatbot, AI...)
- Pattern eşleşmesi yoksa DIRECT akışa düşülür

Adım 5 — Akış Çalıştırma:

- DIRECT: Memory context + OpenAI GPT-4o-mini
- RAG: MongoDB text search + embedding re-rank + GPT-4o-mini
- WEB: DuckDuckGo arama + Claude Sonnet

Adım 6 — Kayıt & Yanıt:

- messages koleksiyonuna user + assistant mesajları yazılır
- trace_logs koleksiyonuna token/cost/latency log yazılır
- ChatResponse objesi oluşturulup döndürülür

---

3. Data Model — MongoDB Koleksiyonları

3.1 sessions

Alan	Tip	Açıklama
_id	ObjectId	MongoDB otomatik ID
session_id	String (unique)	Kullanıcı oturumu tanımlayıcısı
created_at	DateTime	Oturum oluşturulma zamanı (UTC)
message_count	Integer	Toplam mesaj sayısı
metadata	Object	Opsiyonel ek bilgiler

3.2 messages

Alan	Tip	Açıklama
_id	ObjectId	MongoDB otomatik ID
session_id	String	Bağlı oturum ID (index)
role	Enum	user | assistant | system
content	String	Mesaj içeriği
memory_type	Enum	short_term | long_term
created_at	DateTime	Mesaj zamanı (UTC)

metadata	Object	route, model, tokens gibi ek bilgiler

3.3 memory_store

Alan	Tip	Açıklama
_id	ObjectId	MongoDB otomatik ID
session_id	String	Bağlı oturum ID
memory_type	Enum	long_term (özet)
content	String	LLM tarafından üretilen konuşma özeti
updated_at	DateTime	Son güncelleme zamanı
message_count_at_summary	Integer	Özet oluşturulduğundaki mesaj sayısı

3.4 documents (RAG kaynak dokümanlar)

Alan	Tip	Açıklama
_id	ObjectId	MongoDB otomatik ID
title	String	Doküman başlığı (text index)
content	String	Doküman içeriği (text index)
embedding	Array<Float>	OpenAI text-embedding-3-small vektörü (opsiyonel cache)
createdAt	DateTime	Eklenme tarihi

3.5 trace_logs

Alan	Tip	Açıklama
_id	ObjectId	MongoDB otomatik ID
session_id	String	Bağlı oturum ID
message_id	String	İlgili mesaj ID
route_type	Enum	direct | rag | web
model_used	String	gpt-4o-mini veya claude-sonnet-...
token_usage	Object	prompt_tokens, completion_tokens, total_tokens, estimated_cost_usd
processing_time_ms	Integer	Toplam işlem süresi (ms)
rag_doc_count	Integer	RAG'dan alınan doküman sayısı
web_results_used	Boolean	Web araması kullanıldı mı?
routing_reason	String	Routing kararının açıklaması

created_at	DateTime	Log zamanı (UTC)

4. Index Stratejisi

Koleksiyon	Index	Tür	Amaç
sessions	session_id	Unique	Hızlı session lookup
messages	session_id + created_at	Compound	Session mesajlarını kronolojik getir
memory_store	session_id + memory_type	Compound	Session bazlı memory sorgula
documents	title + content	Text	Full-text arama (RAG)
trace_logs	session_id + created_at	Compound	Session bazlı log sorgula

5. Teknoloji Stack

Katman	Teknoloji	Versiyon	Tercih Sebebi
API Framework	FastAPI	0.115	Async, otomatik Swagger, Pydantic entegrasyonu
Veritabanı	MongoDB + Motor	Motor 3.6	Esnek şema, async driver, text search
Küçük LLM	OpenAI GPT-4o-mini	—	Hızlı, ucuz — direct ve RAG akışları
Büyük LLM	Anthropic Claude Sonnet	—	Güçlü reasoning — web akışı
Embedding	text-embedding-3-small	—	Düşük maliyet, yüksek kalite
Web Arama	DuckDuckGo API	—	Ücretsiz, API key gerektirmez
Validation	Pydantic v2	2.9	Type safety, otomatik schema
Server	Uvicorn	0.30	ASGI, yüksek performans