OrchAI

Teknik Karar Matrisi

Routing Kararları | Memory Politikası | Maliyet Kontrolü | Mart 2026

---

1. Routing Karar Tablosu

Her gelen istek aşağıdaki karar hiyerarşisine göre bir akışa yönlendirilir. Karar sırası kritiktir: üstteki kural eşleşirse alttakiler değerlendirilmez.

Öncelik	Kural	Akış	Model	Tetikleyici Örnekler
1 (En Yüksek)	force_route parametresi	Zorunlu	Seçilen	Test senaryoları, debug
2	Direct pattern eşleşmesi	DIRECT	GPT-4o-mini	merhaba, selam, 2+2, tamam, teşekkür
3	Web keyword eşleşmesi	WEB	Claude Sonnet	bugün, güncel, haber, kur, hava durumu, bitcoin
4	RAG keyword eşleşmesi	RAG	GPT-4o-mini	nedir, nasıl çalışır, chatbot, AI, transformer, LLM
5	Soru işareti + uzun mesaj	RAG (deneme)	GPT-4o-mini	5+ kelimeli soru cümleleri
6 (Varsayılan)	Hiçbiri eşleşmedi	DIRECT	GPT-4o-mini	Diğer tüm istekler

1.1 RAG Fallback Kuralı

RAG akışında MongoDB'den doküman bulunamazsa (rag_docs = 0), sistem otomatik olarak DIRECT akışa geçer ve LLM'in genel bilgisiyle yanıt verir. Bu sayede kullanıcıya her zaman bir yanıt döner.

1.2 WEB Fallback Kuralı

Web araması başarısız olursa (DuckDuckGo yanıt vermezse), Claude Sonnet mevcut bilgisiyle yanıt verir ve UTC tarih/saat bilgisini context olarak kullanır.

---

2. Memory Türleri ve Yaz/Oku Kuralları

	Kısa Vadeli (short_term)	Uzun Vadeli (long_term)
Nerede saklanır?	messages koleksiyonu	memory_store koleksiyonu

Ne zaman yazılır?	Her user/assistant mesajında	Mesaj sayısı LONG_TERM_SUMMARY_THRESHOLD (20) katına ulaştığında
Ne zaman okunur?	Her istekte — son N mesaj alınır	Her istekte — önce özet okunur
Format	Ham mesaj listesi [{role, content}]	LLM tarafından üretilmiş özet metin
Kapasite	MAX_SHORT_TERM_MESSAGES (10) mesaj	Sınırsız (tek özet, güncellenir)
LLM'e nasıl verilir?	Mesaj geçmişi olarak	System prompt'a eklenir
Temizleme	DELETE /sessions/{id} ile manuel	DELETE /sessions/{id} ile manuel
TTL/Privacy	Şu an manuel, TTL index eklenebilir	Şu an manuel, TTL index eklenebilir

2.1 Uzun Vadeli Özetleme Akışı

- Mesaj sayısı 20'nin katına ulaşınca tetiklenir (20, 40, 60...)
- Son 20 mesaj alınır ve varsa önceki özet eklenir
- GPT-4o-mini ile 300 kelimelik özet oluşturulur
- memory_store'a upsert ile yazılır (her oturumda tek kayıt)
- Özetleme hatası olursa sistem normal çalışmaya devam eder

2.2 Context Oluşturma Sırası

- 1. Uzun vadeli özet okunur (varsa system prompt'a eklenir)
- 2. Son 10 mesaj okunur (mesaj listesine eklenir)
- 3. RAG veya web context varsa ayrıca system prompt'a eklenir
- 4. Yeni kullanıcı mesajı en sona eklenir
- 5. Toplam paket LLM'e gönderilir

---

3. Maliyet Kontrol Checklist'i

3.1 Model Seçim Stratejisi

Akış	Model	Birim Maliyet (Giriş)	Birim Maliyet (Çıkış)	Kullanım Gerekçesi
DIRECT	GPT-4o-mini	$0.15 / 1M token	$0.60 / 1M token	Hızlı, ucuz — basit sorular
RAG	GPT-4o-mini	$0.15 / 1M token	$0.60 / 1M token	Context zaten hazır, küçük model yeterli
WEB	Claude Sonnet	$3.00 / 1M token	$15.00 / 1M token	Güncel bilgi + uzun context gerekli
Özetleme	GPT-4o-mini	$0.15 / 1M token	$0.60 / 1M token	Arka plan görevi, maliyet kritik

3.2 Token Optimizasyon Kuralları

Kural	Uygulama	Tahmini Tasarruf
Short-term limit	Maksimum 10 mesaj geçmiş gönder	~30-40% prompt token azaltma
Long-term summarize	20+ mesajı özet haline getir	Context şişmesini önler
RAG snippet limit	Doküman içeriğini 800 karakter ile kes	~20% prompt token azaltma
Web snippet limit	Web sonucunu 500 karakter ile kes	~15% prompt token azaltma
Max token limiti	DIRECT:1000, RAG:2000, WEB:2000	Kontrolsüz maliyet önler
Cheap-first routing	WEB sadece gerçekten güncel sorgular için	En pahalı modelin kullanımını sınırlar

3.3 Maliyet İzleme

- Her istekte estimated_cost_usd trace_logs'a yazılır
- GET /sessions/{id}/cost-summary ile session bazlı maliyet özeti alınır
- Route türüne göre maliyet dağılımı görülebilir
- Toplam token ve USD değerleri anlık sorgulanabilir

3.4 Gelecek İyileştirmeler (Roadmap)

- Response cache: Aynı sorgu 24 saat içinde tekrar gelirse cache'den dön
- Embedding cache: Doküman embedding'lerini MongoDB'de saklayarak yeniden hesaplamayı önle
- Daily cost alert: Günlük $X eşiği aşılınca uyarı gönder
- Rate limiting: Session bazlı istek/dakika limiti